

Convenio PLUS TI – Universidad del Valle 2025

Trabajo teórico - práctico 1:

- A) “Métricas custom para reducción de falsos positivos en clasificación binaria: is_fraud:”True”;”False”.
- B) “Entrenamiento de Modelo Federado”.

Objetivo A):

El objetivo de este trabajo es explorar y evaluar distintas estrategias para mejorar la detección de fraudes en un conjunto de datos proporcionado. Actualmente, el modelo presenta una alta tasa de falsos positivos por cada fraude identificado. Para abordar este problema, se propone probar diversas métricas personalizadas en la función de evaluación (**feval**) de LightGBM, con el fin de identificar cuál logra reducir los falsos positivos sin afectar negativamente la capacidad de detección.

Adicionalmente, se busca explorar funciones de evaluación que permitan optimizar aspectos específicos del modelo, como la precisión, la cobertura o la priorización de alertas relevantes.

1. Diseñar y evaluar funciones de evaluación personalizadas enfocadas en reducir la cantidad de falsos positivos por cada fraude detectado. Este será el punto de partida común para todos grupos de estudiantes.
2. Asignar a cada grupo un objetivo específico de optimización, el cual servirá como enfoque principal para desarrollar y ajustar sus modelos.
3. Cada grupo deberá proponer 2 funciones de evaluación distintas alineadas con el objetivo asignado, implementarlas y compararlas entre sí para analizar cuál se desempeña mejor.
4. Seleccionar la función de evaluación más efectiva entre las propuestas, justificando la elección con base en los resultados obtenidos.

Descripción del Dataset

Para este trabajo se debe utilizar el dataset 01_bo_vip_seed22_n100000.csv. Este es un dataset creado sintéticamente con transacciones de tarjetas de crédito de un banco de Bolivia de clientela VIP. El Dataset contiene transacciones legítimas y fraudulentas desde el 1 de enero de 2025 hasta el 30 de junio de 2025. Cubre tarjetas de crédito correspondientes a 5000 clientes que realizan transacciones nacionales e internacionales. Cuenta con 67 variables originales. Se usará como test de evaluación el mes de Junio 2025. El formato del dataset es el ISO 8583 (estándar para tarjetas de crédito).

Metodología

1. EDA

- Cargar el dataset en un entorno de trabajo como Python con Pandas y NumPy.
- Realizar un análisis de distribución y balanceo de clases.

2. Ingeniería de variables

- Crear nuevas variables que aporten información relevante al modelo, como contadores, acumuladores, condiciones. Algunos ejemplos:

- time_since_last_txn_min: Minutos desde la última transacción del mismo cliente. Velocidad anómala = posible fraude.
- txn_count_last_1h: Cantidad de transacciones del cliente en la última hora.
- txn_count_last_24h: Cantidad de transacciones del cliente en las últimas 24 horas.
- amount_zscore_customer: Z-score del monto de la transacción respecto al histórico del cliente. Alta desviación = anómalo.

3. Implementación del modelo base

- Entrenar un modelo inicial con LightGBM utilizando métricas tradicionales como AUC-ROC y F1-score.
- Evaluar el rendimiento inicial en términos de fraude detectado y falsos positivos.

4. Definición de métricas personalizadas

- Implementar diferentes funciones feval para LightGBM, por ejemplo:
- Penalización de falsos positivos.
- Métricas balanceadas que favorezcan una menor tasa de falsos positivos sin reducir drásticamente la detección de fraude.
- La métrica que evaluamos es la ratio de falsos positivos definido como: $\text{ratio falsos positivos} = \text{FP} / (\text{TP} + \text{FP})$.

5. Evaluación de resultados

- Comparar el rendimiento de las distintas métricas feval usando el último trimestre del dataset como testing. El comparativo debería ser la ratio de falsos positivos buscando tener un 90% de detección.
- Determinar cuál estrategia logra el mejor balance entre falsos positivos y detección de fraude.

6. Optimización con objetivos diferenciados por grupos de alumnos

- A cada grupo se le asignará un objetivo de optimización específico, el cual puede estar relacionado con distintos aspectos del desempeño del modelo. En función del objetivo asignado, cada grupo deberá diseñar al menos tres funciones de evaluación personalizadas.
- Ajustar parámetros del modelo y/o pesos de clases según sea necesario para cumplir con el objetivo.
- Evaluar y comparar el rendimiento de cada función diseñada, seleccionando la más efectiva y justificando su elección con evidencia cuantitativa obtenida del modelo

Objetivo B):

Se entregarán los datasets etiquetados de Banco 1 y Banco 2. El dataset de Banco 3 se entregará sin la variable objetivo(is_fraud). Los equipos deberán entrenar un modelo federado utilizando Banco 1 y Banco 2 y generar para cada transacción de Banco 3 una predicción binaria.

Los 3 bancos son de distintos países, con clientela y tipologías de fraude diferentes.

Esta es una práctica muy novedosa y requiere investigación.

El dataset del 3er banco no contiene la marcación del fraude. Deberán entrenar un modelo utilizando la data del Banco 1 y 2, y realizar inferencias sobre el primer 30% de las transacciones del banco 3.

Durante la realización del trabajo práctico deberán enviarnos las inferencias del primer 30% del banco 3 para poder devolverles las métricas sobre cómo van con este 3er dataset.

Con nuestras devoluciones podrán ir identificando qué metodología es la mejor y lo aplicarán al restante 70% del dataset como entrega final.

El objetivo de esta segunda parte del TP es realizar la mejor inferencia sobre el 70% restante de las transacciones del Banco 3.

Metodología

1. EDA

- Cargar los datasets en un entorno de trabajo como Python con Pandas y NumPy.
- Realizar un análisis de distribución y balanceo de clases.

2. Ingeniería de variables

- Crear nuevas variables en los 3 datasets que aporten información relevante al modelo, como contadores, acumuladores, condiciones.

3. Investigar procedimientos y adaptaciones necesarias para entreamientos de Modelos Federados. Entrenar modelo.

- Tener cuidado que el modelo no debe aprender sobre cosas específicas como “banco” o lugar de “fraude”. Debe tener cierto agnosticismo sobre ciertas variables locales que no apliquen como variables globales.
- Es posible tener que realizar algunas transformaciones a los datos, según la estrategia que se decida llevar a cabo.

4. Aplicar, modelo entrenado con datasets 1 y 2 en el banco 3

- Dede el sábado 9/5 hasta el miércoles 3/6 se deben entregar por lo menos 3 inferencias realizadas sobre el primer 30% de las transacciones del dataset 3, con el fin que podamos remitirles a la brevedad los resultados de este primer 30%, y así puedan identificar la mejor metodología.
- Las entregas preliminares de este 30% deben ser por mail, en un archivo Excel que contenga únicamente en la columna A, la variable “is_fraud” indicando: True o False.

5. Aplicar la inferencia final sobre todo el dataset del banco 3 para ser evaluado y presentar métricas de resultado esperado.

- El día 5 de junio deben brindar una presentación y ppt de su trabajo realizado, de una duración de 5 minutos, y entregar el repositorio con el dataset 3 con su inferencia sobre el 100% de las transacciones. A partir de la investigación desarrollada y esta inferencia podremos evaluar el resultado final del Modelo Federado.

Recomendaciones

- Documentar cada paso del proceso en el notebook.
- Utilizar visualizaciones para respaldar el análisis.
- Realizar optimización de hiperparámetros
- Explicar el razonamiento detrás de cada decisión tomada.

Entrega

El trabajo deberá entregarse en forma de un informe técnico de no más de 5 páginas, anexando los notebooks utilizados para la implementación y los resultados de los experimentos A) y B).

El informe debe incluir:

- Resumen
- Metodología
- Descripción de la implementación práctica
- Conclusiones
- Análisis de los resultados de la evaluación, con énfasis en el comparativo de estrategias
- Dataset 3 con la inferencia realizada

✉ info@plusti.com

☎ 706 257 - 6555

📍 1921 Whittlesey Road Suite 500 Columbus, Georgia 31904

Recursos Adicionales

Se puede optar por utilizar Google Colab para facilitar el uso de recursos computacionales, incluyendo GPU si es necesario. Se recomienda el uso de bibliotecas de Python como Scikit-learn, lgbm para la implementación de los modelos.

Link descarga Dataset:

<https://drive.google.com/drive/folders/1zC-LjQzIF2U4XEmXXSLocJWDY6fPnYKc?usp=sharing>

Contacto y mail para envíos de inferencias del 30% y consultas:

- Gabriel Andrade Castejón.
- Mail: gandrade@plusti.com

✉ info@plusti.com

☎ 706 257 - 6555

📍 1921 Whittlesey Road Suite 500 Columbus, Georgia 31904