

DETECCIÓN DE FRAUDE BANCARIO CON MÉTRICAS PERSONALIZADAS Y APRENDIZAJE FEDERADO

Michelle Mejía, 22596

Silvia Illescas, 22376

Davis Roldán, 22672

Guatemala, 05 de junio de 2026

1. Resumen Ejecutivo

La detección de fraude financiero constituye uno de los principales desafíos para las instituciones bancarias modernas debido a la necesidad de equilibrar dos objetivos frecuentemente opuestos: maximizar la detección de transacciones fraudulentas y minimizar la generación de falsas alertas.

En este proyecto se desarrolló una solución basada en Machine Learning orientada a identificar transacciones fraudulentas utilizando información transaccional estructurada bajo el estándar ISO 8583. El trabajo se enfocó particularmente en operaciones relacionadas con establecimientos de hospedaje, segmento asignado como objetivo específico del proyecto.

La solución implementada incluyó análisis exploratorio de datos, ingeniería de variables especializadas, entrenamiento de modelos LightGBM, diseño de métricas personalizadas orientadas a negocio, optimización automática de hiper parámetros y una estrategia de aprendizaje federado para realizar inferencias sobre una institución financiera sin etiquetas de fraude.

Los resultados evidenciaron que las variables relacionadas con comportamiento histórico, velocidad transaccional y cambios geográficos abruptos constituyen los indicadores más relevantes de fraude. Asimismo, se logró mantener niveles de detección superiores al 90% en el segmento objetivo y demostrar capacidad de generalización entre bancos con características transaccionales distintas.

2. Hallazgos de Negocio

El análisis realizado permitió identificar patrones de riesgo consistentes y potencialmente transferibles a escenarios reales de monitoreo transaccional.

Riesgo asociado a velocidad transaccional

Las variables relacionadas con la frecuencia y proximidad temporal entre transacciones demostraron ser los indicadores más importantes para la detección de fraudes. Los eventos fraudulentos tienden a presentar patrones de actividad significativamente más acelerados que las operaciones legítimas.

Riesgo geográfico

Los cambios rápidos entre países y ubicaciones geográficas mostraron una asociación importante con eventos fraudulentos. Este comportamiento puede indicar uso indebido de credenciales o intentos de evasión de controles tradicionales.

Riesgo en establecimientos de hospedaje

Las transacciones relacionadas con hoteles y hospedajes presentaron patrones diferenciados respecto al fraude general, justificando la necesidad de métricas especializadas para este segmento.

Valor del comportamiento histórico

Las variables construidas a partir del historial transaccional del cliente mostraron una capacidad predictiva superior a muchas variables descriptivas tradicionales, confirmando que el contexto de comportamiento es uno de los principales activos para la detección de fraudes.

3. Estrategia Analítica

Análisis Exploratorio de Datos

Se analizaron más de 100,000 transacciones correspondientes al Banco 1, identificando distribución de clases, comportamiento temporal, calidad de datos y patrones asociados al fraude.

El conjunto presentó aproximadamente un 5% de transacciones fraudulentas, reflejando un escenario realista de desbalance de clases. Para evitar fuga de información se utilizó una división temporal, reservando el mes de junio como conjunto de prueba final.

Ingeniería de Variables

Con el objetivo de capturar señales de riesgo no evidentes en las variables originales, se desarrollaron variables derivadas relacionadas con:

1. Velocidad transaccional.
2. Comportamiento histórico del cliente.
3. Frecuencia de uso.

4. Cambios geográficos.
5. Patrones específicos de hospedaje.




Figura 1. Variables con mayor contribución al modelo optimizado.

La importancia de variables muestra que los principales indicadores de fraude corresponden a comportamientos anómalos del cliente más que a características estáticas. Particularmente, las variables relacionadas con sucesión rápida de transacciones, tiempo entre operaciones y desviaciones respecto al patrón histórico dominaron el proceso de decisión del modelo.

Modelo Base y Métricas Personalizadas

Se implementó un modelo Light GBM como línea base y posteriormente se diseñaron múltiples funciones de evaluación personalizadas orientadas a priorizar la detección de fraude en establecimientos de hospedaje.

Estas métricas permitieron incorporar objetivos de negocio específicos al proceso de entrenamiento, penalizando escenarios con alta generación de falsas alertas y favoreciendo altos niveles de cobertura.

Optimización

Posteriormente se utilizó Optuna para realizar optimización automática de hiperparámetros y ajuste de umbrales de decisión.

Esta etapa permitió obtener mejoras consistentes manteniendo una capacidad de detección superior al 90% para el segmento objetivo.

4. Resultados

Resultados del Modelo Base

Métrica	Resultado
ROC-AUC	0.903
PR-AUC	0.772
Precisión	84.9%
Recall	72.4%
F1 Score	0.782

Estos resultados establecieron una referencia sólida para la evaluación de las estrategias posteriores.

Comparación de estrategias

Estrategia	Recall Hotel	FP Ratio Hotel
Baseline	90%	94.0%
Mejor práctica personalizada	90.6%	93.6%
Modelo personalizado	91.4%	93.3%

Los resultados muestran mejoras consistentes en la capacidad de detección manteniendo los niveles de cobertura requeridos para el segmento de hospedaje.

Resultados del Modelo Federado

Modelo	AUC
Banco 1	0.877
Banco 2	0.809
Federado	0.893
Centralizado de referencia	0.890

La estrategia federada alcanzó un desempeño comparable e incluso ligeramente superior al modelo centralizado utilizado como referencia, evidenciando una adecuada capacidad de generalización entre bancos con perfiles transaccionales distintos.




Figura 2. Comparación del desempeño entre modelos locales, federado y centralizado

5. Impacto y conclusiones

Impacto del Proyecto

1. Más de 300,000 transacciones analizadas.
2. Seis métricas personalizadas evaluadas.
3. Recall superior al 90% para el segmento objetivo.
4. Identificación de patrones de fraude transferibles entre bancos.
5. Implementación exitosa de una estrategia federada para inferencia sobre datos sin etiquetar.

Conclusiones y recomendaciones

La ingeniería de variables basada en comportamiento transaccional fue el principal factor de éxito del proyecto, superando en impacto a las mejoras obtenidas únicamente mediante optimización de hiper parámetros.

Las métricas personalizadas permitieron alinear el proceso de entrenamiento con objetivos operativos reales, especialmente en escenarios donde la reducción de falsas alertas es tan importante como la detección del fraude.

Asimismo, la estrategia federada demostró capacidad para transferir conocimiento entre instituciones financieras distintas, permitiendo realizar inferencias sobre conjuntos de datos sin etiquetas y evidenciando el potencial de este enfoque para entornos reales de colaboración interinstitucional.

Como trabajo futuro se recomienda explorar arquitecturas federadas más avanzadas, calibración probabilística y modelos basados en secuencias temporales para continuar mejorando la capacidad de detección y la reducción de falsos positivos.